

به نام خدا
دانشگاه صنعتی امیرکبیر (پلی تکنیک تهران)
دانشکده مهندسی کامپیوتر



یادگیری ماشین
تکلیف هفتم

استاد درس: دکتر صفابخش

امیرحسین کاشانی

۴۰۰۱۳۱۰۷۱

amkkashani@gmail.com

نیم سال اول ۱۴۰۱-۱۴۰۲

فهرست

۳ سوال یک تشریحی)
۳ سوال دو تشریحی (
۴ سوال سه تشریحی)
۵ سوال چهار تشریحی)
۶ سوال یک پیاده سازی)
۷ سوال دو پیاده سازی)
۷ سوال سه پیاده سازی)

سوال یک تشریحی)

نویز نقش مهمی در ورودی شبکه های مولد تقابلی ایفا می کند. در چنین شبکه هایی، مولد نمونه های داده ای را با یک بردار نویز تصادفی به عنوان ورودی تولید می کند. نویز عامل اصلی وجود رندومنس در مولد است و در صورت نبود آن مولد با توجه به یکسان بودن همه شرایط یک خروجی یکسان تولید خواهد نمود. (پدیده mode collapse که در بخش بعدی به آن پرداخته شده است)

تغییر توزیع یا پارامترهای نویز می تواند تأثیر قابل توجهی بر داده های تولید شده و فرآیند آموزش داشته باشد. به عنوان مثال، تغییر توزیع نویز از Gaussian به Uniform یا تغییر مقیاس نویز می تواند تنوع نمونه های تولید شده را تغییر دهد. در برخی موارد، می تواند ثبات روند آموزش را نیز بهبود بخشد و منجر به همگرایی بهتر شود.

نویز یکی از اجزای ضروری شبکه های مولد تقابلی است و توزیع و پارامترهای آن می تواند تا حد زیادی بر کیفیت و تنوع داده های تولید شده و همچنین پایداری و همگرایی فرآیند آموزش تأثیر بگذارد.

سوال دو تشریحی)

Diminished Gradient در شبکه های تقابلی، به موضوع ناپدید شدن گرادیان اشاره دارد. این مشکل زمانی رخ می دهد که generator داده های با کیفیت تولید که به داده های واقعی بسیار نزدیک است در نتیجه discriminator به دلیل تفاوت کم در داده های فیک و واقعی به سختی می تواند آن ها را تشخیص دهد و فرآیند backpropagation با مشکل رو به رو می شود.

راه کار ها :

۱. Label Smoothing : این روش با اضافه کردن مقدار کمی نویز به برچسب داده های واقعی می خواهد از overfit کردن مدل discriminator جلوگیری کند و احتمال کوچک شدن گرادیان ها را کاهش دهد.

۲. استفاده از توابعی که بخش اشباع شده ندارند استفاده شود

۳. one-sided label smoothing: در زمانی که می خواهیم لیبیل مربوط به فیک یا واقعی بودن رو تشخیص دهیم به جای استفاده از ۰ و ۱ برای تعیین یک مقدار اعشاری بر می گردانند و می توانیم در حین آموزش یا قبل از آموزش نحوه قضاوت در رابطه با اینکه از چه مرزی به بعد را حقیقی و از چه مرزی به پایین را فیک در نظر بگیریم بر آموزش کنترل داشته باشیم. این کار از overconfidence در مدل جلوگیری می کند.

۴. gradient penalty : در این روش یک مقدار پنالتی در تابع هزینه قرار داده می شود تا از اینکه گرادیان خیلی کوچک شود جلوگیری کند

Mode collapse به حالتی در شبکه های GAN گفته می شود که مدل به سمت تولید یک سری sample خاص حرکت می کند که شاید آن ها درست باشند اما همگی نزدیک به یک محتوا و یا یک موضوع خاص هستند و به درستی نمی تواند از همه فضای حالت برای ایجاد نمونه بهره گیری کند.

برای مقابله با این پدیده راهکار های متفاوتی ذکر گردیده است:

۱. استفاده از معماری پیچیده تر در بخش مولد مثل استفاده از لایه های بیشتر یا اتصال باقی مانده و ...
۲. Data Augmentation : افزایش تعداد داده های آموزش با اعمالی مانند چرخش و تغییر اندازه تصویر و ... به موجب می شود که مولد بتواند داده های متنوع تری تولید کند
۳. Minibatch discrimination : زمانی که mode collapse اتفاق می افتد همه تصاویر ساختگی شبیه به هم می شوند. برای کاهش شدت این مشکل می توان تصاویر واقعی و ساختگی را در BATCH های و جداگانه به DISCRIMINATOR وارد کرد و با اندکی تغییر در آن بخش از شبکه در لایه های FULLY CONNECTED یک لایه جدید و موازی اضافه شود که وظیفه آن تشخیص شباهت تصویر وارد شده با تصاویر دیگر موجود در آن BATCH است. این موضوع به این شکل به کمک ما می آید که اگر بخش GENERATOR دچار فروپاشی گستردگی شود و تصاویر مشابه تولید کند، بخش DISCRIMINATOR با دیدن شباهت میان تمام تصاویر یک BATCH به ساختگی بودن آن ها پی می برد.

سوال سه تشریحی)


معماری شبکه DC-Gan را به همراه عملکرد لایه های معکوس کانولوشنی توضیح دهید. به نظر شما با ایجاد چه تغییرات و مکانیزم هایی می توان از معماری مذکور برای تولید تصویر از متن ورودی استفاده نمود؟

شبکه DC-Gan مشابه شبکه مولد تقابلی عادی از دو بخش تمایزگر و مولد تشکیل شده با این تفاوت که به جای استفاده از لایه های fully connected یا همان Dense، می خواهد از لایه های پیچش بهره ببرد و با استفاده از CNN بتواند موفقیت های این شبکه در یادگیری با نظارت را در یادگیری بدون نظارت نیز تکرار کند.

در معماری این شبکه به جای استفاده بهره گیری از max pooling برای کوچک تر کردن فضای حالت از stride بزرگ تر استفاده شده است که مدل بتواند عملکرد بهتری در نحوه ذخیره سازی اطلاعات مهم تر داشته باشد.

سومین تغییر نیز در معماری گفته شده بهره گیری از batch normalization می باشد که به آموزش راحت و روان تر مجموعه داده موجب می گردد. این کار در دو بخش مولد و تمایزگر صورت گرفته است.

در بخش generator نیز همگی توابع فعال سازی relu بود و فقط در لایه خروجی از tanh بهره گرفته شده است و در همه لایه های تمایزگر از leaky relu استفاده شده است.



معماری مولد

transposed convolutional وظیفه sampling را بر عهده دارند و باعث می‌گردند تا feature map های ما بزرگ تر از اندازه مرحله قبلی خود شوند. با توجه به عملکردشان در بخش مولد به کار گرفته می‌شوند تا بتوانند تصویر با سازی بزرگ تری در ساینز مورد نظر استفاده کنند و ویژگی های فشرده شده بدست آمده را به تصویر مورد نظر تبدیل کنند.


برای تولید تصویر از متن از ایده ای مشابه شبکه های تقابلی شرطی استفاده می‌گردد به اینصورت که یک داده تعبیه شده (Embed) از جمله مورد نظر به عنوان ورودی به هر دو بخش تمایزگر و مولد داده می‌شود. تمایزگر آموزش در داده های آموزشی خود متن را در کنار تصویر می‌بیند و یاد می‌گیرد که چه تصویر با چه متنی همخوانی دارد. از طرف دیگر مولد مجبور می‌شود برای این که تمایزگر را فریب دهد براساس متن ورودی خود تصویر را ایجاد نماید.

سوال چهار تشریحی)

شبکه های مولد تقابلی از دو جزء تشکیل شده اند، بخش مولد و بخش تمایزگر، بخش تمایزگر سعی دارد تا تشخیص دهد که آیا تصویر واقعی است یا ساختگی و در طرف مقابل بخش مولد سعی دارد تا نمونه ای را تولید کند که تمایزگر نتواند غیر اصل بودن آن را تشخیص دهد و در این جا یک بازی min max بین این مدل برقرار است که می‌توانید آن را در تابع loss مورد نظر مشاهده کنید که مولد می‌خواهد حاصل را کمینه و تمایزگر می‌خواهد آن را بیشینه کند.

$$\min_{\theta_g} \max_{\theta_d} \left[\mathbb{E}_{x \sim p_{data}} \log D_{\theta_d}(x) + \mathbb{E}_{z \sim p(z)} \log(1 - D_{\theta_d}(G_{\theta_g}(z))) \right]$$

آموزش این شبکه بصورت مرحله ای صورت می‌گیرد و در زمانی که بخش تمایزگر در حال آموزش است متغیر های بخش مولد ثابت و زمانی که بخش مولد در حال آموزش است بخش تمایزگر ثابت می‌باشد. معماری کلی شبکه GAN نیز مانند شکل زیر است. تمایزگر دو حالت ورودی می‌گیرد، یک دسته داده های واقعی و یک دسته داده های فیک ایجاد شده که از آن می‌توان خطای مرتبط با هر بخش را محاسبه نمود.




سوال یک پیاده سازی (مقدمه)

تفاوت عمده و اساسی شبکه های مولد تقابلی شرطی با نسخه عادی آن در این است که به ما امکان ایجاد داده در کلاس های متفاوت را می دهد بر عکس حالت عادی که صرفاً یک نمونه از تصویر یا موضوع مورد نظر که فقط نزدیک به نسخه اصلی است ایجاد می کند. در این معماری با استفاده از اطلاعات اضافه تر می توانیم مشخص کنیم که خروجی ما از چه جنسی باشد به بیان دیگر در بین فضای حالات جواب های قابل قبول داریم یک دسته را انتخاب می کنیم.

(بخش اصلی جواب)

حال برای این کار به هر دو بخش generator , discriminator نوع لیبل عکس ها نیز ورودی داده می شود تا از اطلاعات استفاده کنند. در بخش discriminator ، x, y به عنوان دو ورودی مستقل به داده ها وارد می شوند، طبق متن مقاله قبل از اینکه با یک دیگر ترکیب شوند ابتدا هر کدام یک لایه مستقل را طی می کنند که در آن از تابع فعال سازی maxout استفاده شده سپس با یک دیگر ترکیب و به یک لایه متصل می شوند.

y در این حالت به طور خاص برای مساله hand digit ، حالت one hot encoding لیبل ها فرض شده است، این فرض را به طور کلی می توان به مسائل دیگر تعمیم داد اما از روش های دیگر نیز مثل encoding و ... نیز استفاده شده است.



سوال دو پیاده سازی

خروجی تمایزگر در این معماری یک عدد اعشاری یا صفر و یک است که بیان می کند داده واقعی ای است یا خیر، در نتیجه به عنوان جواب اولیه باید گفت که این شبکه درستی لیبل را مشخص نمی کند.

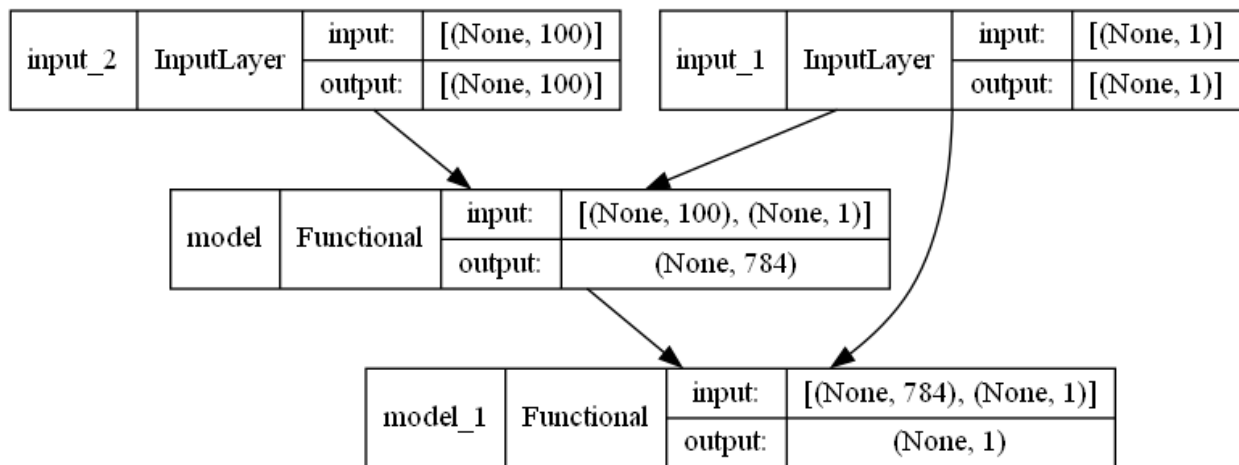
اما به طور ضمنی این شبکه یک پیش فرض ذهنی را آموزش می بیند و آن هم این است که داده های واقعی، لیبل درست دارند و داده های فیک می توانند لیبل اشتباه داشته باشند. در نتیجه ما به طور قطع نمی توانیم از خروجی شبکه متوجه شیم که لیبل درست است یا غلط ولی شبکه ما داده هایی که لیبل با تصویر هم خوانی ندارد را به احتمال قوی در دسته فیک شناسایی می کند ولی داده هایی که لیبل با محتوا یکی است لزوماً داده واقعی شناسایی نمی کند. (به بیان دیگر این درست بودن لیبل را به عنوان یک فیچر بررسی می کند)

سوال سه پیاده سازی

برای این بخش دو مدل ساده و پیچیده آموزش داده شده است.

مدل ساده در بخش مولد از relu و BatchNormalization بدون momentum استفاده شده است ولی در مدل پیچیده تر leakyrelu و momentum ۰.۸ در جاهای قبلی استفاده شده است که همگرایی را سرعت می بخشد.


معماری مدل به چهار قسمت تقسیم شده است که در ابتدا مولد و لیبل ورودی به عنوان دو قسمت با یک دیگر ترکیب می شوند و خروجی آن به بخش بعدی که شامل دو بخش تمایزگر و لیبل ورودی آن است وارد می شوند (در نتیجه ۴ بخش کد وجود دارد که دو به دو ترکیب می شوند و در نهایت بصورت سری به هم وصل می شوند)



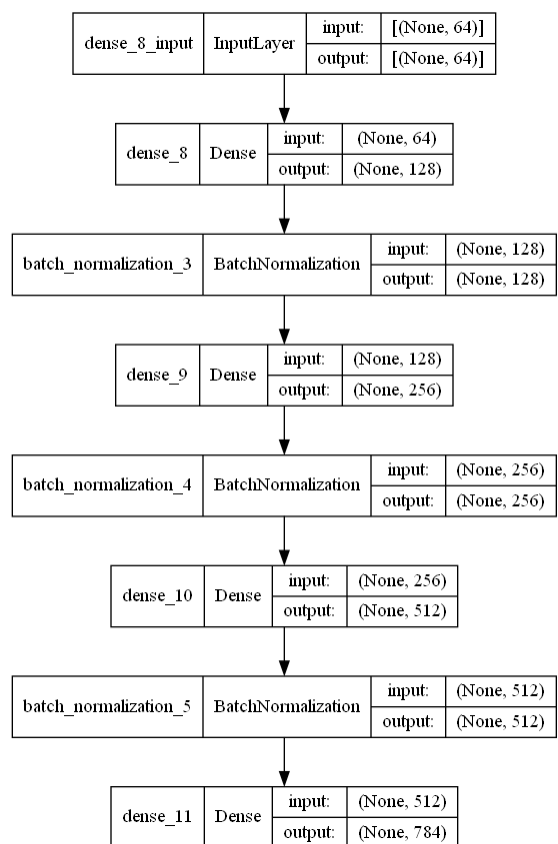
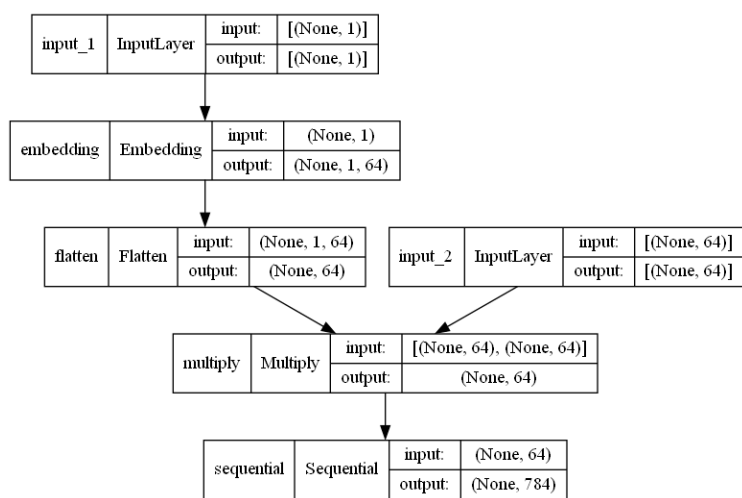

شکل شماتیک کلی هر دو مدل طراحی شده که همان معماری GAN هست

در ادامه جزئیات هر کدام از مدل ها را بیان می‌کنیم.

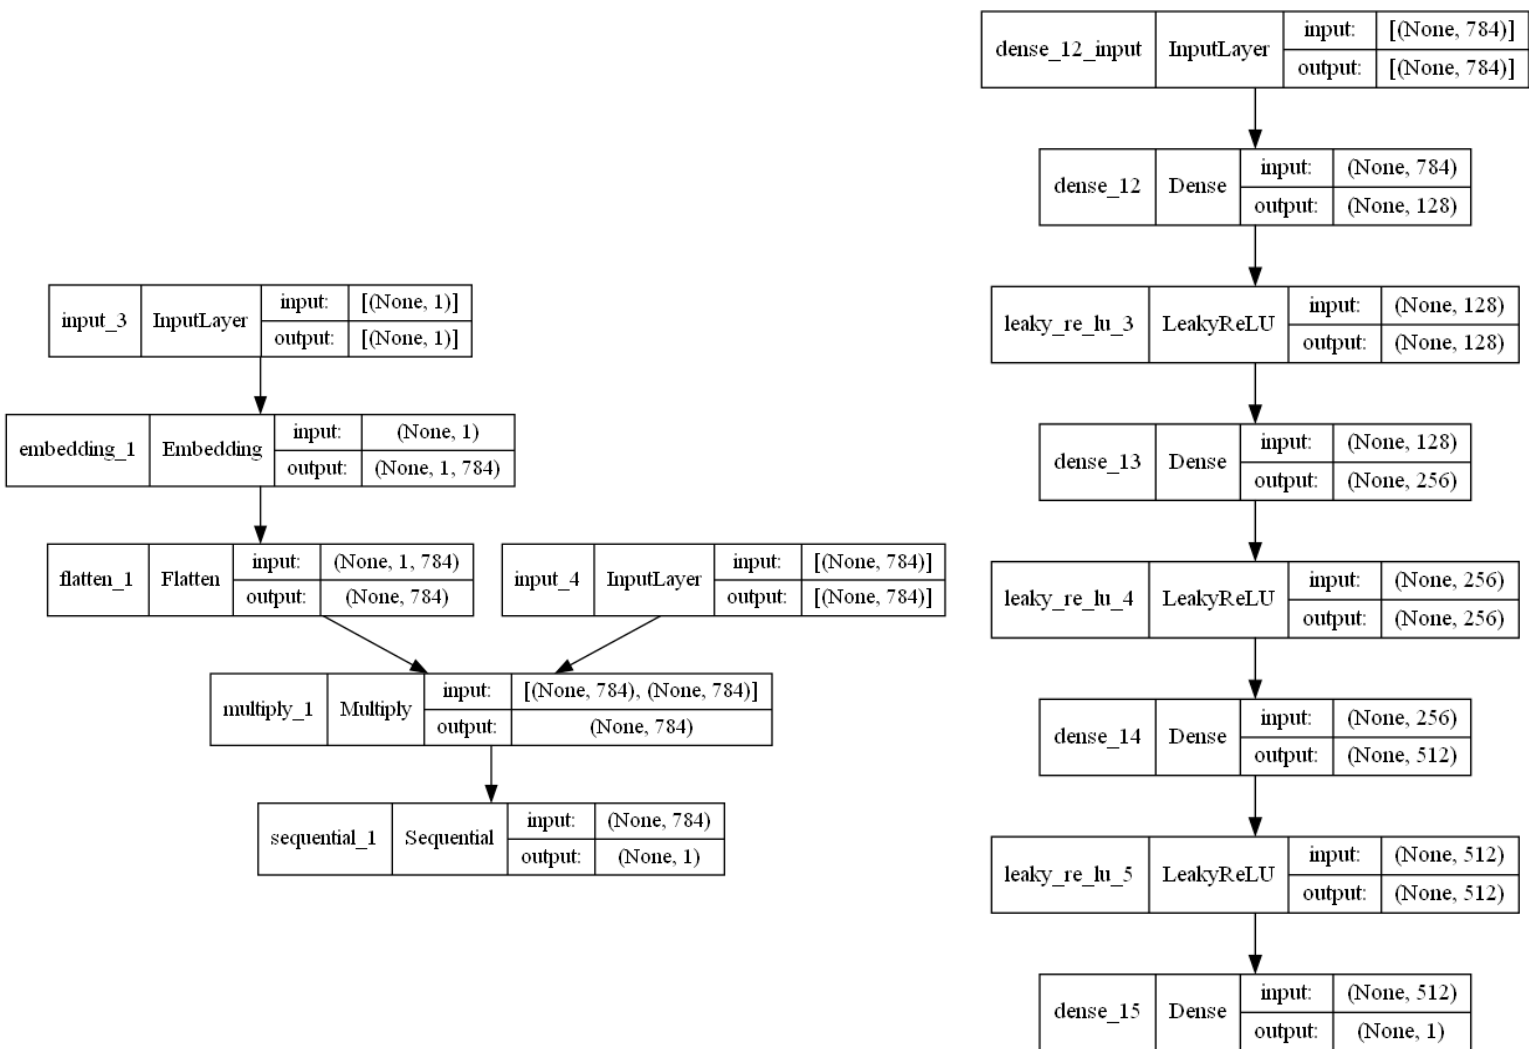
حالت ضعیف تر



خروجی مدل ضعیف تر




شکل سمت راست بخش sequential شکل سمت چپ می‌باشد و در امتداد یک دیگر این شکل بخش مولد را تشکیل می‌دهد




شکل سمت راست بخش sequential شکل سمت چپ می‌باشد و در امتداد یک دیگر این شکل بخش تمایز گر را تشکیل می‌دهد

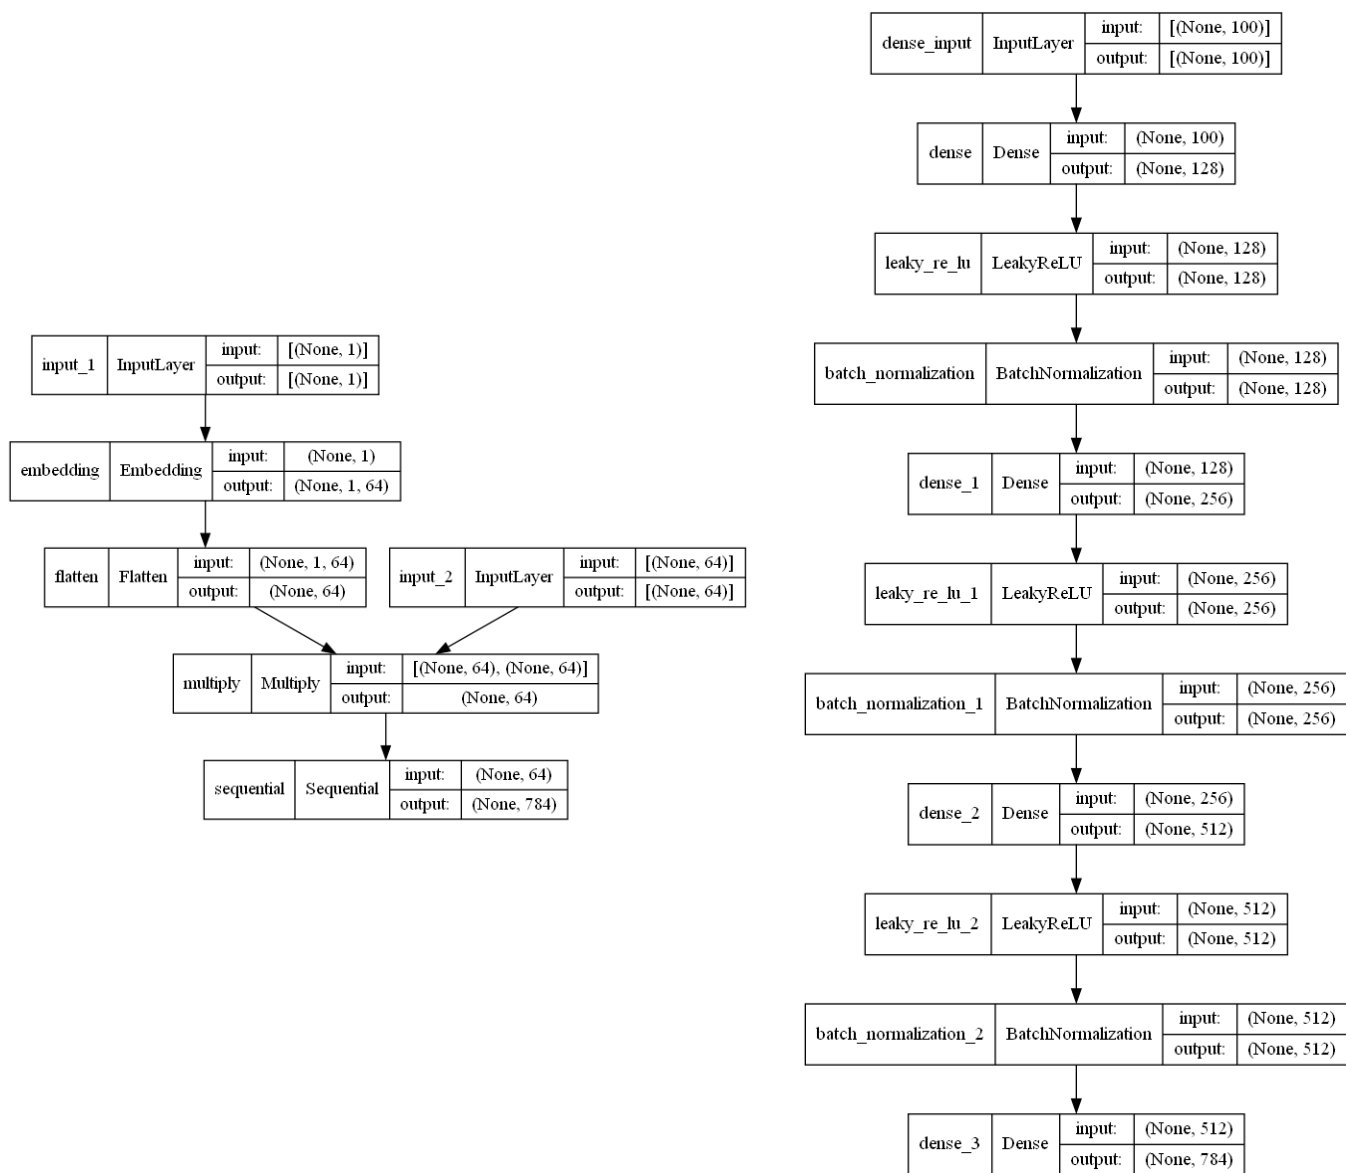
حالت پیچیده تر:



مدل پیچیده تر



معماری این بخش دقیقاً مشابه بخش قبلی فقط در بخش مولد تغییراتی داشته است که به آن در ابتدای این بخش اشاره شده است.



شکل فوق مربوط به بخش مولد می‌باشد.

** gif های مربوط به هر دو مدل در ضمیمه قرار داده شده اند.